L'informatique des entrepôts de données

Daniel Lemire

SEMAINE 11 Notions intermédiaires de MDX

11.1. Présentation de la semaine

Cette semaine, nous poursuivons notre introduction au langage MDX. En particulier, nous allons couvrir les fonctions sur les sets, la fonction CrossJoin, les membres calculés, et la manipulation de la dimension temps.

11.2. Redémarrons

Rappel: La personne qui vous encadre n'a pas accès à votre machine. Elle n'a pas accès à ce que vous avez fait. En cas de problème, faites des saisies d'écran complètes montrant la totalité de vos manipulations techniques depuis le début de la semaine 10 et transmettez-les à la personne chargée de votre encadrement. Elle pourra vérifier avec vous que vous avez suivi toutes les étapes, point par point.

La semaine passée nous avons installé Tomcat et Mondrian. Il faut maintenant relancer Mondrian :

- Retrouvez le dossier dans lequel vous avez placé Tomcat (par exemple, sur votre bureau).
- Si vous utilisez Windows, exécutez le script bin\startup.bat. Si vous utilisez Linux ou Mac OS, exécutez le script bin/s-tartup.sh.
- Vous devez vérifier que Tomcat fonctionne. Visitez le site http://localhost:8080/. Vous devez voir la page d'accueil

de Tomcat. Rappelez-vous qu'en cas de problème, vous pouvez consulter le fichier logs/catalina.out pour consulter les messages d'erreur de Tomcat.

- Rendez-vous à l'adresse http://localhost:8080/mondrian-embedded/. Vous devez voir la page d'accueil de Tomcat de Mondrian.
- Suivez le lien Basic interface for ad hoc queries. Vous êtes maintenant prêt!

11.3. Approche pédagogique

Nous suivons la même approche qu'à la semaine précédente. Vous devez recopier les requêtes MDX et les exécuter. N'oubliez pas que vous pouvez aussi créer vos propres requêtes! Rappelez-vous qu'il n'est pas nécessaire de mémoriser toutes les fonctions MDX (ce serait difficile).

11.4. Une référence incontournable

Il y a beaucoup de fonctions MDX. La semaine passée vous avez pu consulter certaines références sur le web. Cette semaine, je vous invite à consulter le guide de référence de Mondrian : http://mondrian.pentaho.com/documentation/mdx.php. Vous y trouverez une liste exhaustive des fonctions supportées par Mondrian.

11.5. Fonctions sur les membres et les dimensions

Jusqu'à présent, nous avons supposé que nous étions disposé à saisir les différentes valeurs des dimensions. Par exemple, la dimension Product comporte des membres Food et Drink. Mais se rappeler de toutes ces valeurs peut devenir fastidieux.

La fonction Members permet d'obtenir toutes les valeurs (de tous les niveaux hiérarchiques) :

```
select
{[Measures].[Unit Sales]} on columns,
{([Product].Members)} on rows
from [Sales]
   La fonction s'applique à toutes les dimensions :
select
{[Measures].[Unit Sales]} on columns,
{([Time].Members)} on rows
from [Sales]
```

Comme on peut le constater, la liste des valeurs peut être longue ! On peut aussi cibler des éléments qui sont à un niveau précis de la hiérarchie avec la fonction Levels :

```
select
{[Measures].[Unit Sales]} on columns,
{([Product].Levels(2).Members)} on rows
from [Sales]
   Voici un autre exemple:
   select {
      ([Time].Children)
} on columns,
{ ([Store].Levels(1).Members) }
on rows
from [Sales]
```

On peut aussi se contenter de faire les listes des enfants, c'est-à-dire des valeurs qui sont immédiatement en dessous dans la hiérarchie avec la fonction Children :

```
select{
    ([Time].Children)
} on columns,
{([Gender].Members) }
on rows
from [Sales]
```

Notez ici que [Time] a comme valeur par défaut l'année 1997 (cela a été configuré dans la base de données) et que la requête précédente est en fait équivalente à celle-ci :

```
select{
    ([Time].[1997].Children)
} on columns,
{([Gender].Members) }
on rows
from [Sales]
```

Évidemment, la fonction Children est applicable à toutes les dimensions :

```
select
{[Measures].[Unit Sales]} on columns,
{([Product].[Non-Consumable].Children)} on rows
from [Sales]
```

Comme on peut le voir, la fonction Children nous permet de faire un drill-down. Il existe une multitude de fonctions similaires en MDX dont Parent, NextMember, PrevMember, FirstSibling, LastSibling, FirstChild, LastChild, etc. Je vous invite à tester ces fonctions avec les requêtes suivantes :

```
(a) select{
       ([Time].[1997].[Q1].Parent)
   } on columns,
   {([Gender].Members) }
   on rows
   from [Sales]
(b) select{
       ([Time].[1997].[Q1].NextMember)
   } on columns,
   {([Gender].Members) }
   on rows
   from [Sales]
(c) select{
       ([Time].[1997].[Q2].PrevMember)
   } on columns,
   {([Gender].Members) }
   on rows
   from [Sales]
(d) select{
       ([Time].[1997].[Q3].FirstSibling)
   } on columns,
   {([Gender].Members) }
   on rows
   from [Sales]
(e) select{
       ([Time].[1997].[Q3].LastSibling)
   } on columns,
   {([Gender].Members) }
   on rows
   from [Sales]
(f) select
   {[Measures].[Unit Sales]} on columns,
   {([Product].FirstChild)} on rows
    from [Sales]
(g) select
   {[Measures].[Unit Sales]} on columns,
   {([Product].LastChild)} on rows
```

Table 1. Quelques fonctions MI	${ m DX~sur}$	les sets
---------------------------------------	---------------	----------

Fonction	Syntaxe	Description
Head	Head(Set [, expression	Elements de
	numérique])	tête d'un set
Tail	Tail(Set [, expression	Derniers élé-
	numérique])	ments d'un
		set
Subset	Subset(Set , Start [,	Sous-
	Count])	ensemble
		d'éléments
		d'un set
TopCount	1 ()	Les premiers
	expression numérique])	éléments
		ayant la
		plus grande
		valeur de la
0.1	0.1 (0.1 0.1	mesure
Order	Order (Set , String	
	Expression expression	ments d'un
	numérique [, ASC DESC BASC BDESC])	set
Filter	Filter(Set, conditions)	Les éléments
rinei	ritter (Set , conditions)	d'un set qui
		satisfont le
		filtre
Distinct	Distinct(Set)	Élimine les
Distillet	Distinct Set)	duplicats
		аарпсав

```
from [Sales]
(h) select
   {[Measures].[Unit Sales]} on columns,
   Descendants([Product].[Non-Consumable])
   on rows
   from [Sales]
```

11.6. Fonctions sur les sets

La Table 1 donne une liste de fonctions utiles pour manipuler les sets. Encore une fois, pour mieux comprendre le sens de ces fonctions, nous vous proposons quelques exemples.

 On ne veut que les deux premiers trimestres : select { ([Measures].[Unit Sales])

```
DANIEL LEMIRE, ENTREPÔTS DE DONNÉES
6
       }
       on columns,
       {
                (Head([Time].Children, 2))
       on rows
       from [Sales]
     • On ne veut que les trois derniers trimestres :
       select
       {
            ([Measures].[Unit Sales])
       on columns,
       {
                (Tail([Time].Children, 3))
       on rows
       from [Sales]
     • On ne veut que le trimestre avec les meilleures ventes :
       select
       {
            ([Measures].[Unit Sales])
       on columns,
       {
                (Topcount([Time].Children,1,[Measures].[Unit Sales]))
       on rows
       from [Sales]
   On peut combiner différentes listes :
select
{
    ([Measures].[Unit Sales])
}
on columns,
         (Head([Time].Children, 2)),
         (Tail([Time].Children, 3)),
         (Topcount([Time].Children,1,[Measures].[Unit Sales]))
}
```

```
on rows
from [Sales]
   On voit dans cet exemple que certaines valeurs sont répétées. Comme
en SQL, on peut utiliser l'instruction distinct pour éviter que cela soit
le cas:
select
{
    ([Measures].[Unit Sales])
on columns,
distinct( {
        (Head([Time].Children, 2)),
         (Tail([Time].Children, 3)),
         (Topcount([Time].Children,1,[Measures].[Unit Sales]))
})
   On peut ensuite trier les valeurs de telle manière que les mesures
soient en ordre décroissant :
select
{
    ([Measures].[Unit Sales])
}
on columns,
order(distinct( {
        (Head([Time].Children, 2)),
         (Tail([Time].Children, 3)),
         (Topcount([Time].Children,1,[Measures].[Unit Sales]))
}),[Measures].[Unit Sales],DESC)
on rows
from [Sales]
   On peut aussi filter les valeurs de telle manière que seules les mesures
les plus significatives soient affichées, selon un seuil fixe (il s'agit d'une
forme de requête iceberg):
select
{
    ([Measures].[Unit Sales])
on columns,
filter([Time].Children, [Measures].[Unit Sales]>65000)
on rows
from [Sales]
```

11.7. Fonction CrossJoin

Pour réaliser des représentations du type tableau croisé, MDX fournit l'opérateur CrossJoin. Cet opérateur permet de croiser des sets. Plus formellement, étant donné un set A et un set B, CrossJoin construit un nouveau set contenant tous les tuples (a,b) où a est dans A et b dans B:

```
select
{
 CrossJoin
  {([Time].[1997].[Q1]), ([Time].[1997].[Q2])},
  {([Measures].[Unit Sales]), ([Measures].[Store Sales])}
}
on columns,
 ([Product].[Drink].Children)
on rows
from [Sales]
   Il arrive qu'une opération CrossJoin génère des cellules vides :
select
 Crossjoin
  {[Measures].[Unit Sales], [Measures].[Store Sales]},
  {[Time].[1997].[Q1]}
on columns,
 Crossjoin
  {[Promotion Media].[Cash Register Handout],
  [Promotion Media]. [Sunday Paper, Radio, TV],
  [Promotion Media].[TV]},
  {[Gender].Children}
 )
on rows
from [Sales]
   On peut améliorer le résultat avec l'instruction Non Empty :
select
 Non Empty Crossjoin
```

```
(
  {[Measures].[Unit Sales], [Measures].[Store Sales]},
  {[Time].[1997].[Q1]}
on columns,
 Non Empty Crossjoin
  {[Promotion Media].[Cash Register Handout],
  [Promotion Media]. [Sunday Paper, Radio, TV],
  [Promotion Media].[TV]},
  {[Gender].Children}
on rows
from [Sales]
   Voici un autre exemple:
select
 Crossjoin
  {[Measures].[Unit Sales], [Measures].[Store Sales]},
        {[Gender]}
 )
on columns,
  [Promotion Media]
 }
on rows
from [Sales]
   Vous ne pouvez pas mettre plus d'une fois la même hiérarchie dans
plusieurs axes indépendants d'une requête. En exécutant la requête
suivante, vous obtiendrez une erreur:
select
Crossjoin
  {[Measures].[Unit Sales], [Measures].[Store Sales]},
        {[Gender]}
 )
on columns,
  [Gender].[F]
on rows
```

as

from [Sales]

11.8. Membres calculés (with)

```
MDX permet à l'aide du mot-clé with de calculer de nouveaux mem-
bres.
with Member [nom du membre 1] as [<specification>]
Member [nom du membre 2] as [<specification>]
select [<axis_specification>
[, <spécification_des_axes>...]]
from [<spécification_d_un_cube>]
[where [<spécification_de_filtres>]]
   Pour illustrer l'utilisation de with, on se propose d'ajouter un nou-
veau membre calculé [Store Sales by Unit Sales].
with
Member [Measures]. [Store Sales by Unit Sales]
as
  [Measures].[Store Sales] / [Measures].[Unit Sales]
select
  CrossJoin
   {([Time].[1997].[Q1])},
   {([Measures].[Unit Sales]), ([Measures].[Store Sales]),
   [Measures].[Store Sales by Unit Sales]}
  )
 }
on columns,
  ([Product].[Drink].Children)
 }
on rows
from [Sales]
   On peut aussi en profiter pour formater les valeurs avec l'instruction
FORMAT_STRING:
with
Member [Measures]. [Store Sales by Unit Sales]
```

```
(
  [Measures].[Store Sales] / [Measures].[Unit Sales]
FORMAT_STRING = "$#,###.00"
select
 {
  CrossJoin
   {([Time].[1997].[Q1])},
   {([Measures].[Unit Sales]), ([Measures].[Store Sales]),
   [Measures].[Store Sales by Unit Sales]}
  )
 }
on columns,
 {
  ([Product].[Drink].Children)
on rows
from [Sales]
```

Il est plus naturel de créer de nouveaux membres à partir des mesures. Cependant, vous pouvez également en créer sur n'importe quel autre axe. Prenons, l'exemple de l'axe temps. On voudrait, par exemple, calculer l'évolution des mesures [Measures].[Unit Sales] et [Measures].[Store Sales] entre le premier et le deuxième trimestre de l'année 1997. La requête suivante satisfait cette requête.

```
with
   Member [Time].[1997].[Evolution]
as
   (
    ([Time].[1997].[Q2] - [Time].[1997].[Q1]) / [Time].[1997].[Q1]
     ), format_string = "Percent"
select
     {
            ([Measures].[Unit Sales]), ([Measures].[Store Sales])
}
on columns,
      {
            ([Time].[1997].[Q1]), ([Time].[1997].[Q2]),
            ([Time].[1997].[Evolution])
}
on rows
```

```
from [Sales]
```

Vous trouverez des exemples supplémentaires en ligne : http://msdn.microsoft.com/en-us/library/ms146017.aspx.

11.9. Ordre de résolution des membres calculés

Il peut arriver que vous ayez des ambiguïtés si vous utilisez plusieurs membres calculés qui se suivent. Regardons de plus près l'exemple de la requête suivante :

```
with
Member [Measures]. [Store Sales by Unit Sales]
 (
  [Measures].[Store Sales] / [Measures].[Unit Sales]
    ), format_string = '##.##'
Member [Time].[1997].[Evolution]
as
 (
  ([Time].[1997].[Q2] - [Time].[1997].[Q1]) / [Time].[1997].[Q1]
    ), format_string = "Percent"
select
 CrossJoin
  {([Measures].[Unit Sales]), ([Measures].[Store Sales]),
  ([Measures].[Store Sales by Unit Sales])},
  {([Time].[1997].[Q1]), ([Time].[1997].[Q2]),
  ([Time].[1997].[Evolution])}
 )
on rows,
 {
    ([Product].[Drink])
 }
on columns
from [Sales]
```

On se rend compte que l'on calcule non pas le pourcentage d'évolution des [Store Sales by Unit Sales], mais le ratio des évolutions entre le pourcentage d'évolution de [Unit Sales] (-1.36%) et le pourcentage d'évolution de [Store Sales] (2.84%). Ce qui ne veut absolument rien dire (une perte de 209%). Le calcul effectué est (0.0284+0.0136)/(-0.0136)=-2.09.

Pour éviter ce type d'erreur, il est possible de spécifier un ordre de résolution des membres calculés à l'aide du mot-clé solve_order :

```
with
Member [Measures]. [Store Sales by Unit Sales]
as
  [Measures].[Store Sales] / [Measures].[Unit Sales]
    ), solve_order = 0, format_string = '##.##'
Member [Time].[1997].[Evolution]
as
 (
  ([Time].[1997].[Q2] - [Time].[1997].[Q1])
  / [Time].[1997].[Q1]
    ), solve_order = 1, format_string = "Percent"
select
CrossJoin
 {([Measures].[Unit Sales]), ([Measures].[Store Sales]),
 ([Measures].[Store Sales by Unit Sales])},
 {([Time].[1997].[Q1]), ([Time].[1997].[Q2]),
 ([Time].[1997].[Evolution])}
)
on rows,
{
   ([Product].[Drink])
on columns
from [Sales]
```

11.10. Exemples de manipulation de la dimension temps

La navigation temporelle est un point important et communément utilisée dans l'OLAP afin de mener des analyses comparatives. Dans ce cas, MDX permet de résoudre un certain nombre de questions de manière élégante et évite de construire des hiérarchies temps trop rigides. Nous nous employons ici à donner quelques exemples significatifs de questions couvertes de manière simple par le MDX.

11.10.1. Analyse comparative (ParallelPeriod)

L'analyse comparative consiste à présenter à côté d'une mesure, la même mesure sur une période parallèle qui lui est antérieure. Prenons l'exemple de la requête suivante; la mesure [Unit Sales] est affichée en parallèle sur les trimestres en cours et antérieur.

```
with
Member [Measures]. [Unit Sales Q-1]
as
 (
    ParallelPeriod([Time].[1997].[Q1], 1)
select
 {
  ([Measures].[Unit Sales]), ([Measures].[Unit Sales Q-1])
on columns,
    {
     ([Time].Children)
on rows
from [Sales]
   La fonction ParallelPeriod a la signature suivante :
ParallelPeriod(["niveau[, "expression numérique"
[, "membres" ]]])
```

où niveau représente la période, sur laquelle on veut remonter dans le temps, l'expression numérique donne le nombre de périodes, et membre permet de fixer un membre sur la dimension temps.

Dans notre exemple, nous n'avons pas spécifié de membre. La valeur par défaut étant Dimension.currentMember (chaque dimension a une valeur par défaut fixée par le schéma). Mondrian va donc chercher dynamiquement pour chaque ligne ou chaque croisement le même membre sur deux périodes (ici le trimestre précédent).

11.10.2. Calcul cumulatif

Il arrive souvent qu'on ait besoin de calculer des cumuls sur une période de temps. Prenons dans notre cas le calcul du cumul de la mesure [Unit Sales] durant l'année 1997. Dans un premier temps, calculons le total des ventes par trimestre.

Comment faire la même chose, mais avec les mois? On peut envisager un accès par membre, mais l'expression correspondante est un peu longue :

Une façon plus élégante et moins fastidieuse d'obtenir la même chose est d'utiliser la fonction Descendants. Elle retourne un ensemble de descendants d'un membre sur un niveau ou à une distance spécifiée, et en option permet d'inclure ou d'exclure des descendants d'autres niveaux. Dans l'exemple qui suit, nous calculons les descendants d'une distance égale à deux (mois) à partir de l'année 1997.

```
select
    {
        ([Measures].[Unit Sales])
    }
on columns,
    {
        Descendants([Time].[1997],2)
        --L'appel ci-dessous donne le même résultat
        --Descendants([Time],[Time].[Month])
    }
on rows
```

from [Sales]

La requête suivante donne les descendants du niveau mois du membre dont la valeur est le deuxième semestre.

```
select
    {
        ([Measures].[Unit Sales])
    }
on columns,
      {
        Descendants([Time].[1997].[Q2],[Time].[Month])
    }
on rows
from [Sales]
```

La fonction Descendants peut avoir un troisième paramètre optionnel, appelé drapeau pouvant prendre les valeurs suivantes :

- Self: Renvoie seulement les membres descendants à partir d'un niveau donné ou à une distance donnée. Le membre donné en entrée est renvoyé si le niveau donné est le niveau de ce membre.
- After : Renvoie les membres descendants de tous les niveaux subordonnés d'un niveau ou à une distance donnée.
- Before : Renvoie les membres descendants à partir de tous les niveaux entre un membre et un niveau donné, ou à une distance donnée. Le membre donné en entrée est renvoyé mais pas les membres à partir du niveau ou de la distance donnée.
- Before_And_After : Renvoie les descendants membres à partir de tous les niveaux subordonnés d'un niveau d'un membre donné. Le membre donné en entrée est renvoyé mais pas les membres à partir du niveau ou de la distance donnée.
- Self_And_After : Renvoie les descendants membres à partir d'un niveau ou à une distance donnée, et à partir de tous les niveaux subordonnés du niveau ou de la distance donnée.
- Self_And_Before : Renvoie les descendants membres à partir d'un niveau ou à une distance donnée, et à partir de tous les niveaux entre le membre et le niveau donné ou la distance donnée, incluant le membre donné en entrée.
- Self_Before_After : Renvoie les descendants membres à partir des niveaux subordonnés d'un niveau d'un membre donné. Le membre donné en entrée est également renvoyé.
- Leaves : Renvoie les descendants feuilles entre un membre et un niveau donné ou à une d'une distance donnée.

Cette requête renvoie tous les membres dont le niveau est le descendant hiérarchique du niveau 1 (trimestre) de la dimension Time :

```
select
    {
        ([Measures].[Unit Sales])
    }
on columns,
        {
            Descendants([Time],1, After)
        }
on rows
from [Sales]
```

La requête qui suit donne tous les membres dont le niveau est le supérieur hiérarchique du niveau 2 (mois) de la dimension Time.

```
select
    {
        ([Measures].[Unit Sales])
    }
on columns,
        {
            Descendants([Time],2, Before)
      }
on rows
from [Sales]
```

La requête suivante renvoie tous les membres du niveau 1 (trimestre) et ceux des niveaux qui les suivent hiérarchiquement (mois).

```
select
    {
        ([Measures].[Unit Sales])
    }
on columns,
        {
            Descendants([Time],1, SELF_AND_AFTER)
        }
on rows
from [Sales]
```

La fonction YTD (year-to-date) renvoie un set contenant les membres de même niveau en commençant par le membre début et en terminant par le membre fourni en paramètre. On peut aussi utiliser la fonction plus générale PeriodsToDate où la période peut être une année,

un trimestre ou un mois. Il existe également d'autres fonctions comme MTD (month-to-date), QTD (quarter-to-date), WTD (week-to-date).

Dans notre cas, nous voulons cumuler (agrégation à l'aide de la fonction Sum) la valeur d'une mesure à partir d'une date début jusqu'à la date en cours (à l'aide de la fonction currentMeembre d'un membre donné). Dans l'exemple suivant, nous calculons le cumul de [Unit Sales] par intervalle d'un mois de l'année 1997. Si on voulait avoir le cumul par intervalle d'un trimestre, il suffit de reculer d'un niveau les descendants de la dimension [Time].

11.10.3. Formules conditionnelles

Parmi les fonctionnalités les plus intéressantes de MDX, il y a celle de pouvoir réaliser des tests conditionnels à l'aide du mot-clé IIF. La syntaxe de IIF est simple: IIF (condition, resultat si vrai, resultat si faux).

(Attention à la syntaxe: il s'agit bien de IIF et non pas de IF ou de IFFF. Par ailleurs, la fonction IIF prend 3 paramètres, jamais 2 ou 4.)

Dans l'exemple qui suit, nous construisons plusieurs membres dont:

Measures .[Q-1] : donne [Unit Sales] au trimestre précédent,

Measures .[Evolution] : donne l'évolution de [Unit Sales] entre deux trimestres consécutifs,

Measures [%]: donne l'évolution en pourcentage,

Measures .[Performance] : renvoie une chaîne de caractères qui nous permet d'appliquer des règles de gestion liées à des conditions

```
with
Member [Measures].[Q-1]
as
 (
 ParallelPeriod([Time].[1997].[Q1],1, [Time].CurrentMember),
 [Measures].[Unit Sales]
Member [Measures]. [Evolution]
as
 (
    ([Time].CurrentMember, [Measures].[Unit Sales])
    - (ParallelPeriod([Time].[1997].[Q1],1, [Time].CurrentMember),
    [Measures]. [Unit Sales])
 ), solve_order = 1
Member [Measures].[%]
 ([Measures].[Evolution] /
     (ParallelPeriod([Time].[1997].[Q1],1,[Time].CurrentMember),
      [Measures].[Unit Sales])
 ), format_string = "Percent", solve_order = 0
Member [Measures]. [Performance]
 iif([Measures].[Q-1] <> 0,
     iif([Measures].[%] > 0, "-",
         iif([Measures].[%] < 0 and [Measures].[%] > 0.01, "+",
          iif([Measures].[%] < 0.01 and
               [Measures].[%] > 0.05, "++", "better performance")
    )),"null")
Select
     ([Measures].[Unit Sales]),
     ([Measures].[Q-1]),
     ([Measures].[Evolution]),
     ([Measures].[%]),
     ([Measures].[Performance])
    }
on columns,
        Descendants([Time], 1)
```

on rows from [Sales]

Vous trouverez d'autres exemples en ligne : http://msdn.microsoft. com/en-us/library/ms145994.aspx.